



**TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA
PROJELERİ DESTEKLEME PROGRAMI**

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Burak Cankurt
Araştırma Önerisinin Başlığı: İnsanlaştırılmış (Humanized) Yapay Metinlerin Tespiti İçin Stilometrik + Transformer Tabanlı Üç Sınıflı Bir Model Geliştirilmesi
Danışmanın Adı Soyadı: Hüseyin ABACI
Araştırmanın Yürütüleceği Kurum/Kuruluş: Adnan Menderes Üniversitesi – Bilgisayar Mühendisliği Bölümü

ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsamı beklenir. Bu bölümün en son yazılması önerilir.

Bu araştırmada, yapay zekâ tarafından üretilmiş metinlerin paraphrasing/humanizer araçları (Quillbot, Wordtune, Parrot AI, GPT-Rewrite vb.) kullanılarak tespit sistemlerinden kaçırılması problemi ele alınmaktadır. Mevcut AI içerik tespit araçlarının büyük bölümü yalnızca iki sınıflı (AI vs İnsan) ayırım yapabilmekte olup, “insanlaştırılmış” (humanized) metinlere karşı ciddi zaaf göstermektedir [1, 2, 3]. Bu proje, söz konusu zaafı gidermek amacıyla üç sınıflı bir sınıflandırma modeli geliştirmeyi hedeflemektedir: (1) İnsan yazımı akademik metin, (2) Doğrudan LLM çıktısı olan ham yapay metin, (3) Paraphrase/humanizer araçlarıyla istatistiksel özellikleri değiştirilen humanized metin.

Önerilen yöntemde stilometri tabanlı metrikler ile Transformer tabanlı dil modeli embedding’leri birleştiren hibrit bir yaklaşım kullanılacaktır. Stilometrik özellikler; cümle uzunluğu varyansı, kelime çeşitliliği (Type-Token Ratio), n-gram entropisi, fonksiyon kelime oranları, bağlaç örüntü yoğunluğu, sözdizimsel ağaç derinliği, kelime frekansı dağılımının Kullback–Leibler uzaklığı gibi 30’un üzerinde istatistiksel metrikten oluşacaktır. Bu özellikler, BERTurk veya RoBERTa-turkish modellerinden elde edilen 768–1024 boyutlu embedding vektörleriyle early-fusion yöntemiyle birleştirilecektir [12, 13, 14]. Ardından XGBoost, CatBoost, MLP ve Logistic Regression modelleriyle karşılaştırmalı eğitim yapılacak [18, 19], en iyi sonuçlar stacking ensemble modeliyle optimize edilecektir.

Proje yönetimi kapsamında ilk ay veri toplama ve ön işleme faaliyetleri, ikinci ay model geliştirme ve hiperparametre optimizasyonu, üçüncü ay performans değerlendirme ve XAI tabanlı analizler gerçekleştirilecektir. Model başarısı Accuracy, Macro-F1, ROC-AUC, klasman ayırım oranı ve paraphrased metinlerde adversarial robustness ölçütüyle değerlendirilecektir. Hedef doğruluk değerleri: Accuracy $\geq$ %90, Macro-F1 $\geq$ %85, paraphrased metinlerde sınıflandırma doğruluğu $\geq$ %80’dir.

Projenin yaygın etkisi, Türkiye’de bulunmayan “Humanized AI Text Detection Dataset – TR” veri setinin oluşturulması, akademik dürüstlük ve yapay içerik farkındalığının artırılması ve akademik kurumların LLM tabanlı içerik tespit kapasitesinin geliştirilmesi olarak öngörülmektedir.

Anahtar Kelimeler: Humanized AI Detection, Stilometri, Transformer Embedding, NLP, Türkçe Akademik Metin Analizi

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.

Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi’nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Yapay zekâ modellerinin (LLM) akademik metin üretme kapasitesinin artması [11], içerik denetimi ve akademik dürüstlük açısından yeni bir saldırı vektörü doğurmuştur: yapay metinlerin paraphrasing veya humanizer araçlarıyla tespit sistemlerinden kaçırılması [5, 6]. Literatürde DetectGPT, GPTZero, OpenAI Text Classifier gibi araçlar yalnızca ham yapay metinleri tespit etmeye odaklanmakta, humanized metinleri büyük oranda insan yazısı olarak sınıflandırmaktadır [2, 3, 4]. Bu durum “adversarial rephrasing” olarak bilinir ve hâlihazırda çözüm bulunmayan açık bir araştırma problemidir [5, 6].

Bu proje, literatürdeki önemli bir eksikliği gidermeyi amaçlamaktadır: üç sınıflı sağlam bir model (Human – AI – Humanized-AI) [7, 8]. Türkçe için humanized metinleri inceleyen veya üçlü sınıflandırma yapan herhangi bir akademik çalışma bulunmamaktadır [7]. Stilometri + Transformer hibrit yaklaşımı hem makine üretimi hem de

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

paraphrase manipölasyonları altında ortaya çıkan istatistiksel izleri yakalamayı hedeflemektedir [8, 9]. Bu yöntem uluslararası literatürde önerilmiş değildir; özellikle bağlaç örüntüsü analizi, sintaktik derinlik varyansı ve token entropisi gibi metriklerin paralel kullanımı araştırma açısından yenilik taşır.

Ek Teknik Katkı:

Bu çalışmanın özgün yönü, stilometrik metriklerin yalnızca yüzeysel kelime istatistikleriyle sınırlı kalmaması [16]; parse-tree depth variance, conjunctive-fluidity ratio, function-word entropy, LLM-perplexity türev analizi, embedding uzayında principal direction collapse, cosine-neighborhood dispersion, norm-variance gibi modern NLP güvenlik metriklerini derinlemesine incelemesidir [8, 9]. Humanizer araçları yüzeyi değiştirirken bu derin yapısal metriklerde bozulmalar oluşturur [5]. Bu proje, Türkçe için bu anomalileri eşzamanlı modelleyen ilk teknik çalışmadır. Araştırma sorusu:

“Transformer tabanlı derin dil temsilleri ile stilometrik özelliklerin birleşimi, Türkçe humanized yapay metinleri ayırt etmek için yeterli ayırt ediciliği üretir mi?”

Hipotezler:

- H1: Early-fusion hibrit özellik uzayı üç sınıflı ayırmada yüksek performans sağlar.
- H2: Humanized metinler, ham yapay metinlere kıyasla daha düşük dilsel entropi, farklı bağlaç dağılımı ve syntactic-depth varyansı sergiler.

1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Projenin temel amacı, Türkçe metinlerde insan yazımı, doğrudan yapay zekâ üretimi ve humanizer araçlarıyla manipüle edilmiş yapay metinlerin ayırt edilebilmesi için stilometrik özellikler ve Transformer embedding'lerinin birleşiminden oluşan yüksek doğruluklu bir tespit modeli geliştirmektir.

Bu kapsamda hedefler şunlardır:

1. Türkçe akademik metinlerden, LLM çıktılarından ve paraphrased/humanized içeriklerden oluşan dengeli üç sınıflı bir veri seti oluşturmak.
2. Her metin için cümle uzunluğu varyansı, kelime çeşitliliği, POS dağılımı, bağlaç yoğunluğu, syntactic-depth, kelime üretim olasılığı (perplexity) gibi 30+ stilometrik özelliği hesaplamak [16].
3. BERTurk ve RoBERTa-turkish modellerinden embedding çıkararak 768–1024 boyutlu derin temsil elde etmek [12, 13, 14, 15].
4. Stilometri + embedding erken-füzyonu ile yüksek boyutlu bir hibrit özellik uzayı oluşturmak.
5. XGBoost, CatBoost, Logistic Regression ve MLP tabanlı modelleri karşılaştırarak en yüksek performansı veren yapıyı seçmek [18, 19].

Model yalnızca sınıf tahmini vermeyecek; her metin için:

- LLM-distance score,
- stilometrik anomaly heatmap,
- conjunction-deviation index,
- token entropy drop score,
- syntactic-depth shift metriği

gibi ikincil çıktılar da üreterek tespit edilen humanization işleminin hangi dilsel izlerden kaynaklandığını gösterecektir.

Bu sayede tespit sistemi sadece sınıflandırma değil, aynı zamanda akademik metinlerde humanizer araçlarının kullandığı manipölasyon tekniklerini de analiz eden açıklanabilir bir yapıya dönüşecektir.

2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

Bu projede kullanılacak yöntem, insan yazımı, doğrudan yapay zekâ çıktısı ve humanizer araçlarıyla manipüle edilmiş metinlerin ayrılabilmesi için stilometri tabanlı istatistiksel özellikler [16] ile Transformer embedding'lerinin [12, 13] bütünleştirildiği hibrit bir yaklaşımı temel alır.

Öncelikle veri seti üç kaynaktan oluşturulacaktır:

2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

1. Gerçek akademik metinlerden alınmış insan yazımı içerikler,
2. GPT-4, Gemini, Claude ve Llama modelleriyle üretilmiş yapay metinler [10, 11],
3. Bu metinlerin QuillBot, Wordtune, ParrotAI vb. ile yeniden yazılmasıyla oluşturulmuş humanized içerikler [5].

Ön işleme aşamaları:

- temizleme ve normalizasyon,
- tokenizasyon,
- cümle bölme,
- POS etiketleme,
- dependency parsing,
- perplexity ölçümü,
- burstiness hesaplaması.

Ardından stilometrik özellikler çıkarılacaktır:

Cümle uzunluğu varyansı, kelime çeşitliliği, entropi, bağlaç kullanım oranları, POS frekans vektörü, syntactic-depth ortalaması, burstiness index, function-word ratio vb.

Embedding çıkarımı için BERTurk ve RoBERTa-turkish modelleri kullanılacaktır (768–1024 boyut) [14, 15]. Bu özellikler "early-fusion" yaklaşımıyla tek bir vektörde birleştirilecektir.

Ek Teknik İşleme Aşamaları:

- Early-fusion sonrası özellikler z-score standardizasyonu,
- VIF (variance inflation factor) ile çoklu doğrusal bağımlılık analizi,
- mutual information temelli feature pruning,
- cosine distance-based feature clustering,
- embedding anisotropy ölçümleri uygulanacaktır.

Modelleme Aşaması:

- XGBoost → depth, min_child_weight, colsample_bytree, eta [18]
- CatBoost → ordered boosting, shrinkage [19]
- MLP → 3 katmanlı ReLU mimarisi
- Logistic Regression → L2 düzenleme

Hiperparametre optimizasyonu Optuna ile yapılacaktır [20].

Tüm eğitim 5-fold CV ile gerçekleştirilecektir.

Değerlendirme:

- Her fold için confusion matrix,
- sınıf bazlı F1,
- macro F1,
- ROC-AUC,
- embedding-space separation (UMAP grafik) hesaplanacaktır [22].

Model Açıklanabilirliği:

SHAP analiziyle [21]:

- global önem dağılımı,
- humanized metinlerde anomalinin hangi stilometrik izlerden kaynaklandığı,
- feature-level contribution dağılımı raporlanacaktır.

Bu yöntem, Türkçe humanized AI içeriklerinin derin yapısal bozulmalarını tespit etmeye yönelik ilk kapsamlı çalışmadır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmanın başarısına katkısı “Çalışma Takvimi” doldurularak sunulur.

ÇALIŞMA TAKVİMİ (*)

Tarih Aralığı	Faaliyetler**	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmanın Başarısına Katkısı***
01/02/2026-01/03/2026	Veri toplama: İnsan metinleri, ham yapay metinler ve humanized metinlerin derlenmesi; ön işleme (temizleme, tokenizasyon, POS ve dependency analizi)	Burak Cankurt	En az 9.000 örneklik, dengeli (3 sınıf × 3.000) bir veri setinin tamamlanması; modelin yüksek doğrulukla eğitilebilmesi için gerekli temel veri altyapısının oluşturulması
01/03/2026-01/04/2026	Stilometrik özellik çıkarımı, Transformer embedding üretimi ve hibrit (early-fusion) özellik vektörlerinin hazırlanması; model geliştirme ve hiperparametre optimizasyonu	Burak Cankurt	30+ stilometrik özellik ve 768/1024 boyutlu embedding'lerin başarıyla birleştirilmesi; model doğruluğunun ≥ %85 seviyesine ulaşması
01/04/2026-01/05/2026	Model değerlendirme, adversarial robustness testi, SHAP tabanlı açıklanabilirlik analizi, sonuçların yorumlanması ve proje raporunun hazırlanması	Burak Cankurt	Nihai model doğruluğunun ≥ %90, Macro-F1 skorunun ≥ %85, humanized metinlerde F1 skorunun ≥ %80 olması; araştırma çıktılarının rapor hâline getirilip tamamlanması

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.

(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

3.2 Risk Yönetimi

Araştırmanın başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmanın başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B Plan(lar)ının uygulanması araştırmanın temel hedeflerinden sapmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

RİSK YÖNETİMİ TABLOSU*

En Önemli Riskler	Alınacak Tedbirler (B Planı)
Veri çeşitliliğinin yetersiz olması. Humanized metin varyasyonları sınırlı olabilir	Farklı paraphraser araçları + farklı saldırı modları kullanılacak

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Transformer embedding'in yüksek hesaplama maliyeti. GPU erişimi gerekebilir	Colab Pro / üniversite GPU laboratuvarı kullanılacak
Modelin overfitting yapması. Dataset karmaşıklığı yüksek	Regularization, dropout, 5-fold CV
Humanized ve Human sınıflarının benzermesi. Sınıflar arası dağılım yakın olabilir	Stilometri özellikleri artırılacak, ensemble model kullanılacak

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	Projede Kullanım Amacı
Bilgisayar Mühendisliği Laboratuvarı	Veri ön işleme, stilometrik analiz, model eğitimi ve değerlendirme süreçlerinin yürütülmesi
Üniversite ağ bağlantısı ve bilgisayar laboratuvarı internet erişimi	Akademik açık kaynaklardan veri toplama, API erişimi ve model geliştirme ortamlarının kullanılması
Açık kaynak NLP kütüphaneleri (PyTorch, Transformers, SpaCy, Stanza, Scikit-Learn)	Embedding üretimi, istatistiksel özellik çıkarma, model eğitimi ve değerlendirme
Google Colab Pro / Kaggle GPU ortamı	Yüksek hesaplama gücü gerektiren model eğitim süreçlerinde ek GPU kaynağı olarak kullanılması
YÖK Tez Merkezi ve açık erişim akademik makale arşivleri	İnsan yazımı akademik metinlerin etik şekilde toplanması ve veri setinin oluşturulması

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

Çıktı, Etki ve Kazanımlar	Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	Proje sonucunda geliştirilecek hibrit stilometri + Transformer modeli, humanized yapay metin tespiti alanındaki mevcut boşluğu doldurmayı amaçlamaktadır. Elde edilen bulguların ulusal veya uluslararası bir konferansta bildiri olarak sunulması planlanmaktadır. Ayrıca oluşturulacak "Humanized AI Text Detection Dataset – TR" veri seti açık kaynak olarak paylaşılacak ve Türkçe NLP çalışmalarına yeni bir araştırma altyapısı sağlayacaktır.
Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	Geliştirilecek model, üniversitelerde akademik dürüstlük ve metin güvenliği süreçlerinde kullanılabilecek yerli bir prototip tespit aracı niteliği taşımaktadır. Veri seti ve örnek kullanım senaryoları, eğitim kurumlarında düzenlenecek etkinliklerde yapay içerik güvenliği farkındalığının artırılmasına katkı sağlayacaktır. Humanized yapay metinleri tespit eden ilk Türkçe model olması, hem akademik hem de toplumsal düzeyde önemli bir farkındalık oluşturma potansiyeli taşımaktadır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar
(Ulusal/Uluslararası Yeni Proje vb.)

Proje çıktıları, ileride yürütülebilecek ulusal veya uluslararası araştırma projelerine (TÜBİTAK 1001, 1512, Horizon Europe vb.) altyapı sağlayacaktır. Özellikle adversarial NLP, içerik doğrulama, LLM güvenilirliği ve stilometrik sahtecilik tespiti gibi alanlarda yeni iş birlikleri ve geniş kapsamlı projelerin geliştirilmesine katkı sunacaktır.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

Bu projede kullanılacak tüm insan yazımı metinler yalnızca kamuya açık akademik kaynaklardan temin edilecek olup, hiçbir kişisel veri veya özel içerik işlenmeyecektir. Yapay ve humanized metinler yalnızca araştırma amacıyla üretilecek ve etik kurallar çerçevesinde kullanılacaktır. Ayrıca veri seti oluşturulurken içeriklerin telif ve lisans düzenlemelerine dikkat edilecek, tüm süreç etik ilkelere uygun şekilde yürütülecektir.

6. EKLER

EK-1

1. Ippolito, D., Duckworth, D., Callison-Burch, C., & Eck, D. (2020). Automatic detection of generated text is easiest when humans are fooled. Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics (ACL 2020), pp. 1808–1822. arXiv:1911.00650
2. Mitchell, E., Lee, Y., Khazatsky, A., Manning, C. D., & Finn, C. (2023). DetectGPT: Zero-shot machine-generated text detection using probability curvature. Proceedings of the 40th International Conference on Machine Learning (ICML 2023). arXiv:2301.11305
3. Gehrmann, S., Strobelt, H., & Rush, A. (2019). GLTR: Statistical detection and visualization of generated text. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics: System Demonstrations, pp. 111–116. arXiv:1906.04043
4. Zellers, R., Holtzman, A., Rashkin, H., Bisk, Y., Farhadi, A., Roesner, F., & Choi, Y. (2019). Defending against neural fake news. Advances in Neural Information Processing Systems 32 (NeurIPS 2019).
5. Krishna, K., Song, Y., Karpinska, M., Wieting, J., & Iyyer, M. (2023). Paraphrasing evades detectors of AI-generated text, but retrieval is an effective defense. Advances in Neural Information Processing Systems 36 (NeurIPS 2023). arXiv:2303.13408
6. Sadasivan, V. S., Kumar, A., Balasubramanian, S., Wang, W., & Feizi, S. (2023). Can AI-generated text be reliably detected? Transactions on Machine Learning Research (TMLR). arXiv:2303.11156
7. Wang, Y., Mansurov, J., Ivanov, P., Su, J., Shelmanov, A., Tsvigun, A., Whitehouse, C., Afzal, O. M., Mahmoud, T., Sasaki, T., Arnold, T., Aji, A. F., Habash, N., Gurevych, I., & Nakov, P. (2024). M4: Multi-generator, multi-domain, and multi-lingual black-box machine-generated text detection. Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL 2024), pp. 1369–1407. arXiv:2305.14902
8. Uchendu, A., Le, T., Shu, K., & Lee, D. (2020). Authorship attribution for neural text generation. Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP 2020), pp. 8384–8395.
9. Verma, V., Fleisig, E., Tomlin, N., & Klein, D. (2024). Ghostbuster: Detecting text ghostwritten by large language models. Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT 2024), pp. 1702–1717.
10. Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. ACM Computing Surveys, 55(12), 1–38. <https://doi.org/10.1145/3571730>
11. Brown, T., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. Advances in Neural Information Processing Systems 33 (NeurIPS 2020). arXiv:2005.14165
12. Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems 30 (NeurIPS 2017). arXiv:1706.03762
13. Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of the 2019 Conference of the North

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

-
- American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT 2019), pp. 4171–4186. arXiv:1810.04805
14. Schweter, S. (2020). BERTurk — BERT models for Turkish. Zenodo.
<https://doi.org/10.5281/zenodo.3770924>
 15. Jawahar, G., Sagot, B., & Seddah, D. (2019). What does BERT learn about the structure of language? Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL 2019), pp. 3651–3657.
 16. Stamatatos, E. (2009). A survey of modern authorship attribution methods. Journal of the American Society for Information Science and Technology (JASIST), 60(3), 538–556.
<https://doi.org/10.1002/asi.21001>
 17. Fagni, T., Falchi, F., Gambini, M., Martella, A., & Tesconi, M. (2021). TweepFake: About detecting deepfake tweets. PLOS ONE, 16(5), e0251415. <https://doi.org/10.1371/journal.pone.0251415>
 18. Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD 2016), pp. 785–794. arXiv:1603.02754
 19. Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: Unbiased boosting with categorical features. Advances in Neural Information Processing Systems 31 (NeurIPS 2018), pp. 6639–6649. arXiv:1706.09516
 20. Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD 2019), pp. 2623–2631.
<https://doi.org/10.1145/3292500.3330701>
 21. Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems 30 (NeurIPS 2017), pp. 4765–4774. arXiv:1705.07874
 22. McInnes, L., Healy, J., & Melville, J. (2018). UMAP: Uniform manifold approximation and projection for dimension reduction. Journal of Open Source Software. <https://doi.org/10.21105/joss.00861>.
arXiv:1802.03426